DESAFIO INTEGRADOR / RELATÓRIO TÉCNICO

HealthSearch

BM25 + busca vetorial + Reciprocal Rank Fusion

O protótipo combina **correspondência exata** para códigos e termos com **proximidade semântica** para expressões relacionadas. O resultado é auditável: cada documento exibe os scores de origem, seus ranks e as duas parcelas que formam o score híbrido.

01 Arquitetura e fluxo de recuperação

Etapa	Implementação
Corpus e limpeza	Seis trechos do enunciado fixos no arquivo Python; títulos apenas como metadados. BM25 recebe minúsculas, remoção de acentos/pontuação e stopwords em português. CÓD-ECG-12D e ECG-12D viram **ecg12d**; números de códigos e doses são preservados.
Motor léxico	**BM25Okapi** de rank_bm25. Sliders: k_1 de 0 a 3 (1,2) e b de 0 a 1 (0,75). O índice é recalculado por configuração. Para $k_1 = 0$, usa-se o limite por presença do termo, evitando 0/0.
Motor vetorial	Sentence-Transformers **multilingual-e5-small**: 384 dimensões, prefixos query:/passage:, texto original e norma L2. Cosseno explícito entre consulta e trechos. Modelos e vetores do corpus ficam em cache; execução em CPU.
Fusão e re-ranking	RRF ponderado sobre os seis ranks de cada fonte. α de 0 a 1 (0,5), k_RRF = 60. Checkbox aplica o Cross-Encoder multilíngue **mmarco-mMiniLMv2-L12-H384-v1** somente ao Top-3; a cauda mantém a ordem do RRF.

$$S_{RRF}(D) = \alpha / (60 + r_{BM25}) + (1 - \alpha) / (60 + r_{sem})$$

Convenção de empate: ranks começam em 1; scores iguais compartilham o menor rank (1, 1, 3). A identificação de empates usa 12 casas decimais. ID apenas estabiliza a exibição e o corte Top-3. Uma fonte sem sinal acrescenta a mesma parcela a todos os documentos.

02 Modo offline e interface

A **simulação documentada**, aceita pelo desafio e selecionada inicialmente, ativa oito conceitos por expressões declaradas no código. Uma projeção ortonormal fixa (semente 42) gera 32 dimensões densas, preservando o cosseno. Ela depende desse dicionário, não aprende sinônimos novos nem distingue doses.

As abas **Léxico, Semântico, Híbrido RRF e Matriz Comparativa** mostram trechos, fórmulas, ranks, parcelas RRF, gráfico e CSV. A tela mede tempo por etapa e compara P@3, Recall@3 e nDCG@3 nas cinco consultas com gabarito didático. O Cross-Encoder mostra logits, posições antes/depois e variação de nDCG@3.

03 Escopo e limites

O corpus contém **CÓD-ECG-12D nos Docs 1 e 6**, mas não contém a dose **AAS 100mg**. O aplicativo sinaliza códigos/doses ausentes. Resultados próximos não comprovam ocorrência exata. Seis trechos e gabaritos propostos não sustentam generalização clínica nem ganho garantido do híbrido.

Validação: passaram 10 testes de cálculo, extremos, códigos/doses, empates, re-ranking e interface (AppTest). Também foram executados embeddings reais (6 × 384) e Cross-Encoder em três pares.

Resultados e organização

Comparação reproduzível de ranks e divisão proposta da equipe

Configuração medida: embeddings neurais multilíngues (384D); $k_1 = 1,2$; $b = 0,75$; $\alpha = 0,5$; $k_{RRF} = 60$. Corpus original, sem re-ranking no gráfico. Menor rank indica melhor posição.

“ataque cardíaco”

	BM25	Vetorial	RRF
Doc 1	1*	3	3
Doc 2	1*	1	1
Doc 3	1*	6	6
Doc 4	1*	5	5
Doc 5	1*	4	4
Doc 6	1*	2	2

“ataque cardíaco CÓD-ECG-12D”

	BM25	Vetorial	RRF
Doc 1	2	1	1
Doc 2	3	3	3
Doc 3	3	6	6
Doc 4	3	5	5
Doc 5	3	4	4
Doc 6	1	2	1

Figura 1. Ranks calculados pelo próprio aplicativo. 1* = todos os scores BM25 são zero; é empate sem evidência. Células com o mesmo rank também representam empates.

nDCG@3	BM25	Vetorial	RRF
Sinônimo	0,436	0,920	0,920
Sinônimo + código	0,631	1,000	0,815

Gabaritos didáticos: sinônimo → Docs 1 e 2; consulta composta → Doc 1 (ambos os componentes). Relevância binária; métricas consideram permutações uniformes nos empates, inclusive no corte Top-3. Sem amostra independente.

04 Divisão proposta de tarefas

Responsável funcional	Tarefas e evidências
Integrante 1	Ingestão, tokenização, proteção de códigos/doses e motor BM25; conferir k_1 e b.
Integrante 2	Embeddings, cosseno, cache e documentação da simulação; conferir consultas com sinônimos.
Integrante 3	RRF, empates e Cross-Encoder Top-3; conferir fórmula, candidatos e mudança de posições.
Integrante 4	Interface Streamlit, métricas, testes integrados, gráfico e relatório; revisão com a equipe.

Proposta por função: os nomes e a divisão efetivamente realizada devem ser confirmados pela equipe.

Execução: `python -m streamlit run healthsearch_app.py`. Instalação no cabeçalho do script.

Referências técnicas

[1] rank_bm25: implementação BM25Okapi. [2] Sentence-Transformers: modelo multilíngue. [3] Cross-Encoder: modelo mMARCO. [4] Streamlit: cache. Corpus e fórmula RRF: enunciado fornecido. Consulta às fontes: 07 set. 2026.